

180 份考卷批次批改與 PDF 產出流程說明

給助教參考的標準作業流程 (AdaGrade 版)

本文件說明如何將全班學生的掃描考卷匯入課程自架的 AdaGrade 系統，依同一份 rubric 進行 AI 輔助批改、人工複核與發布，並為每位學生產出完整的批改 PDF 與成績彙整（由系統寄送至學生信箱）。

版本： v2.1（取代 v1.0 的 ChatGPT 網頁流程）

日期： 2026-07-20

適用情境： 單題或多題手寫答案批改、逐字轉錄、AI 輔助評分、強制人工抽查、發布與 regrade

系統名稱： AdaGrade（前身 ADA-Marker；伺服器指令與環境變數仍沿用 adamarker / ADAMARKER_* 舊名）

閱讀說明

紅字為相對 v1.0（ChatGPT 網頁流程）新增或改寫的內容；黑字為沿用 v1.0 的原則與規範。
v1.0 原始文件保留於 docs/ta_batch_grading_guide_v1.pdf 供對照。

目錄

1	核心原則	2
2	檔案整理方式	2
2.1	建議檔名	2
2.2	建議 roster 表格	2
3	建議工作流程	3
3.1	第一階段：校準批	3
3.2	第二階段：正式批改	3
3.3	第三階段：複核與定案	3
4	評分規準草案：以本題 15 分為例	3
5	指令範本：由系統內建模板取代	4
6	品質控管建議	5
6.1	人工抽查	5
6.2	需要標記人工複查的情況	5
6.3	分數一致性檢查	5
7	隱私與檔案保存	6
8	系統的開門與資源控管（取代 v1 的上傳限制）	6
9	助教操作清單	6
10	檔案結構：系統儲存與助教留存	7
11	建議時程	7
12	資料來源	8
	附錄：v1 → v2 變更總覽	9

1 核心原則

一句話摘要

不要一開始就處理 180 份。先用 5–10 份代表性答案做校準，確認轉錄保真度、批改風格、評語密度與配分標準後，**再對全班一次啟動正式批改——正式批改不再需要人工分批。**

建議把整個工作視為一個「可稽核的批次批改流程」，而不是單次對話中的大量檔案處理。在 v2 中，可稽核性由系統內建：每一筆批改紀錄自動保留原始掃描頁、遮罩後影像、逐字轉錄、逐條給分與評語、API 成本，以及當時使用的 rubric 版本與批改方法版本，事後隨時可回查。

最重要的提醒

手寫答案批改必須避免「幫學生補完答案」。轉錄時應保留學生原始用詞、錯字、英文文法錯誤、符號錯誤與推導跳躍。若字跡不清，應明確標記為不確定，而不是猜成正確答案。**此規則已寫入系統內建的批改模板：模型被要求逐字轉錄（數學以 LaTeX 表示）、禁止補寫，字跡無法辨認時必須將該筆 confidence 標為 illegible，而非自行猜測。**

與 v1 最大的差異：批改不再經過 ChatGPT 網頁。AdaGrade 是課程自架的服務，考卷影像先遮罩學生身分才會送往視覺模型，全流程在自己的主機與課程控制的 API 金鑰之間完成，學生資料不會進入任何第三方的對話介面或檔案庫。

2 檔案整理方式

2.1 建議檔名

不再需要逐題裁切影像或以匿名編號逐一命名（v1 的 Q5_001.png 命名法作廢）。依掃描方式擇一路徑：

- **逐生 PDF (Submissions 分頁)**：檔案已按學生分開時使用。每位學生一個 <student_id>.pdf（檔名即學號），第 i 頁對應第 i 題。檔名比對不到名冊的檔案會進入隔離區（quarantine），由助教手動指派。
- **整疊掃描 (Identify 分頁)**：考卷成疊過掃描機時使用。答案頁需有三個手寫表頭欄位——學號、姓名、題號（如 Q1）。散頁順序不拘，整疊掃成一個或多個 PDF（可多 GB）或圖片 zip 直接上傳，系統逐頁辨識並歸位到「學生 × 題目」矩陣。

不需要預先裁切題目區域：系統以「頁」為處理單位，依題號欄位自動歸位，批改時模型看到的是遮罩後的整頁影像。

2.2 建議 roster 表格

另外準備一份名冊 CSV。格式為 UTF-8、表頭固定三欄 student_id,name,email（Excel 請用「CSV UTF-8」另存），於系統的 **Students** 頁匯入。重複匯入採更新合併（upsert），不會自動刪除任何人；加退選後重新匯入即可，退選需在差異提示中明確按下 Withdraw 確認。

```
student_id,name,email
b11902001,王小明,b11902001@ntu.edu.tw
b11902002,李小華,b11902002@ntu.edu.tw
```

學生真實姓名與作答影像的對應由系統持有並隔離——視覺模型只看得到遮罩後影像，看不到學號與姓名（見第 7 節），因此不再需要另外維護「匿名編號對照表」。

3 建議工作流程

開始前的一次性設定 (v2 新增)：(1) **Providers** 頁加入 API 金鑰與要用的模型，並填入每百萬 token 單價——單價驅動成本估算與月度預算煞車；(2) **Methods** 頁建立批改方法（供應商 + 模型 + 提示模板 + 寬嚴政策 lenient / standard / strict）；(3) 每題建立配分與 rubric 條目（各條目配分加總必須等於該題滿分），並為每題撰寫參考解答——預設方法會對照參考解答批改，範圍內任何一題缺少參考解答時，系統會直接拒絕啟動批改。

3.1 第一階段：校準批

第一批請選 5–10 份代表性答案，而不是直接處理全班。建議包含：

- 一份寫得很好、接近滿分的答案；
- 一份中等答案；
- 一份明顯錯誤或空泛的答案；
- 幾份字跡較不清楚、術語混淆或推導跳躍的答案。

校準批的目的不是快速產出成績，而是確認以下事項：

1. 轉錄是否足夠忠實；
2. 評語的密度與具體程度是否符合教師期待；
3. 同一類錯誤的扣分是否一致；
4. 需要人工複查的情況是否被正確標記；
5. 批改結果與評語的呈現格式是否適合寄給學生。

系統內的做法：完成匯入、識別與遮罩審核後，對選定的 5–10 份答案逐份啟動 **answer** 範圍的 **run**（每次一份、啟動前有成本預覽，單份成本極低）；或先由助教人工評分數份，之後在 **Analysis** 分頁的方法卡檢視 AI 與人工的差距（平均差、完全一致率、差距一分以內的比率）。rubric 或提示需要修改時，建立新版本後重跑同一批答案即可——舊紀錄連同所用版本一併保留，可直接前後對照。（校準批目前需逐份啟動；「一鍵抽樣 N 份」為規劃中功能。）

3.2 第二階段：正式批改

校準完成後，直接對整場考試（assessment 範圍）或單一題（problem 範圍）啟動 **run**，一次涵蓋全班——v1「每批約 10 位、共 18 批」的分批法是 ChatGPT 上傳限制的產物，在 v2 不存在。啟動入口在考試的 **Overview** 分頁（Start AI grading）或 **Runs** 頁；啟動前系統顯示批改單元數（題數 × 人數）與成本估計，可另設單次 **run** 成本上限；設定月度預算時，會超出預算的啟動將被拒絕並顯示數字。遮罩審核未全數通過前無法啟動（見第 7 節）。

3.3 第三階段：複核與定案

run 完成後在 **Review** 分頁逐題複核：處理強制抽查樣本（見 6.1）、逐一檢視 confidence 為 low / illegible 或被旗標的個案，必要時填入人工分數——人工分數是「後援」（fallback），在最終成績來源未涵蓋之處生效。若同一批答案跑過多個方法，可在 **Consensus** 分頁做事後聚合（多數決或平均、具容錯，純後處理、不重新呼叫 API）。所有分數在 **Publish** 分頁選定「最終成績來源」（單一 AI run 或 consensus）之後才成為正式成績——這是 v2 的關鍵概念：AI 給分永遠只是候選，正式與否由來源選定與發布動作決定。

4 評分規準草案：以本題 15 分為例

以下 rubric 可作為校準起點。實際使用前，授課教師可依課堂標準調整。

項目	配分	評分重點
A. 演算法核心想法正確	6	正確使用 longest common subsequence 或 LPS dynamic programming，可得高分。若只有反轉字串的想法但未正確連到 subsequence，可部分給分。若使用 longest common substring 取代 subsequence，屬核心概念錯誤。
B. 正確性說明	4	說明為什麼演算法輸出的結果是 longest palindromic subsequence。若只有直覺說法，應部分扣分；若完全沒有 correctness argument，應大幅扣分。
C. 時間複雜度推導	3	清楚說明 DP table 大小為 $n \times n$ ，因此時間為 $O(n^2)$ 。只寫出 $O(n^2)$ 但沒有理由時，只能部分給分。
D. 表達與術語精確性	2	檢查 subsequence、substring、common string、string/string(s) 等用詞。英文單複數或小語病可作評語；若術語混淆影響演算法意義，應扣分。

本題特別容易出現的錯誤

本題題目要求的是 palindromic subsequence，不是 substring。若學生把問題轉成 longest common substring，則演算法通常不是本題要求的問題。此錯誤不是單純英文用字問題，而是可能改變演算法內容的概念錯誤。

系統內的對應：把本表建成該題的 rubric 條目（6 + 4 + 3 + 2 = 15，加總必須等於滿分，否則無法儲存）；「特別容易出現的錯誤」這類說明寫進條目描述或參考解答，批改模型與人工複核者都會看到。rubric 修改會產生新版本，舊紀錄記得自己是用哪一版評的。

5 指令範本：由系統內建模板取代

v1 需要在每批上傳時貼上的 prompt 範本已不再使用。批改提示是系統內建的 transcribe-then-grade 模板（「提示詞即韌體」，隨批改方法一起版本化），v1 範本的各项規則在 v2 的對應如下：

v1 prompt 規則	v2 對應
逐字轉錄、不更動用詞、不翻譯、保留錯字與文法錯誤	內建模板強制逐字轉錄，數學與虛擬碼以 LaTeX 表示；模板明文禁止修正或補完學生內容。
\unclear{可能的字}、\illegible{} 逐字標記	對應為整題的 confidence 標記（high / medium / low / illegible）；low 與 illegible 自動列入人工複查對象。（v1 的逐字級標記較細，v2 目前為整題級——這是已知取舍。）
不要補上學生沒有寫出的內容	同左，內建於模板；空白或無法辨認一律標 illegible、不給推測分。
XeLaTeX + ctex + base64 內嵌圖片的 .tex 輸出	不適用。系統直接產出結果 PDF（發布信附件），不再經過 .tex 編譯。
像論文 review comments 一樣列出具體問題	模板要求逐條 criterion 給分並附具體評語；評語隨紀錄保存、可人工修改。

v1 prompt 規則	v2 對應
輸 出 batch_scores.xlsx、 batch_flags.csv、zip	不適用。成績、旗標與複查狀態都在系統內，見第 10 節的匯出方式。

批改風格的要求不變：不要只寫「不夠完整」；要具體指出哪一步推導錯、哪裡有 logical gap、哪個術語使用錯誤、哪個 claim 沒有 justification、哪裡與題目要求不符，並區分 conceptual error、terminology error、proof gap、complexity justification issue、minor English/notation issue。若要讓模型明確依此分類產出評語，可把這段要求寫入自訂方法的提示模板——方法可版本化，並能在 Analysis 中與其他方法並排比較。

注意：修改提示模板等同建立新的方法版本，改完應先重跑校準批確認行為，再用於全班。

6 品質控管建議

6.1 人工抽查

每批至少抽查 2-3 份。抽查時應看三件事：

1. 原始影像與轉錄文字是否一致；
2. 分數是否符合 rubric；
3. 評語是否具體、可解釋、沒有幫學生補答案。

v2 把抽查升級為強制開門：以某個 run 作為最終成績來源時，系統會抽出 $\min(\max(5, 5\%), 20)$ 份、跨題分層的固定樣本，需在 **Runs** 頁逐份人工複核通過，否則無法大量採納該 run 的分數或發布（管理員可明示豁免）。抽樣是確定性的，重新整理不會換題。

6.2 需要標記人工複查的情況

下列情況建議標記為需人工複查：

- 字跡模糊或有多種合理讀法；（系統以 confidence low / illegible 自動標記）
- 學生答案使用非標準但可能正確的方法；（在 Review 加旗標並人工給分）
- 分數落在邊界，例如 6/15 與 7/15、10/15 與 11/15 難以決定；
- 圖片裁切不完整；（多為掃描歪斜——在識別矩陣檢視原頁即可發現）
- 答案跨頁或包含未上傳的補充內容；（特別注意：系統目前一個「學生 × 題目」儲存格只容納一頁，同題第二張紙會以 conflict 停在 Identify 待處理區、不會自動併入，需以並排選擇工具擇一保留——保留任一頁都等於捨棄另一頁。遇到跨頁作答務必人工確認內容完整，再決定給分。）
- 演算法名詞寫錯但推導可能表示學生其實知道正確概念。

6.3 分數一致性檢查

所有批次完成後，建議依分數排序，抽查同分或相鄰分數的答案。例如比較所有 7 分、8 分與 9 分的答案，確認扣分標準一致。若某類錯誤在前後扣分不同，應回頭調整並記錄調整理由。v2 中 **Analysis** 分頁提供分數分布與方法間比較；「同分並排檢視」目前仍需 Review 依分數瀏覽，一鍵並排為規劃中功能。若調整 rubric 後重跑，舊 run 的紀錄不會被覆蓋，可直接前後對照扣分差異。

7 隱私與檔案保存

去識別化：由系統執行

學生考卷屬於敏感教育資料。v1 要求上傳前手動裁去姓名學號；v2 由系統執行：完成識別 (finalize) 後，系統自動以學號與姓名欄位的位置預置遮罩框，助教套用並逐頁審核遮罩結果。遮罩審核未全數通過前，任何 **AI run** 都無法啟動；送往視覺模型的一律是遮罩後影像——身分辨識 (學號 OCR) 與答案批改分離處理，模型永遠不會同時看到「這個人是誰」與「他寫了什麼」。

學號辨識預設走本機 OCR 模型 (伺服器端以 `make ocr-models` 安裝)；「把未匹配的學號欄位送雲端模型辨識」是預設關閉的選項，勾選並明確指定供應商才會送出。兩者都沒有時，頁面進入人工識別佇列，資料完全不出機器。

v1 關於 ChatGPT Library 與 30 天檔案保留政策的整段說明已刪除——v2 不再把任何考卷資料放進第三方對話服務。批改 API 的輸入依各供應商條款處理，但送出的影像已遮罩、不含學生身分。

檔案保存：系統每晚自動備份，順序固定為 blobs (影像) → 金鑰 → 資料庫傾印，確保備份彼此一致；還原程序與異地副本建議見 `docs/OPERATIONS.md`。系統日誌政策禁止記錄學生姓名、學號、信箱與作答內容。

8 系統的閘門與資源控管 (取代 v1 的上傳限制)

v1 的 512 MB / 20 MB / 每次 10 檔限制不適用：整疊多 GB 的掃描 PDF 可直接上傳，批次大小不再由上傳限制決定。取而代之，v2 用四道閘門控管流程品質：

1. 遮罩審核閘門——遮罩未全數審核通過，不能啟動 AI run；
2. 供應商閘門——被停用的供應商無法啟動 run，避免必然失敗的批次；
3. 覆蓋率閘門——仍有學生未評分或有答案非正式時，不能發布；
4. 抽查閘門——最終來源為方法 run 時，抽查樣本未複核完不能發布 (見 6.1)。

成本煞車有兩道：單次 run 可設成本上限；另可設定全系統月度預算，估計後會超出預算的啟動直接被拒絕。模型單價由操作者在 Providers 頁維護，成本估算與月報表都以它為準。

掃描品質提醒：若頁面的文字未能存留於渲染影像 (常見於未內嵌的中文字型)，系統會對該頁提出警示——AI 批改的是渲染後影像，請比對原始檔並重新匯出或重掃。

建議設定

- 校準批：5–10 位學生。
- 正式批改：全班一次 run (assessment 或 problem 範圍)，啟動前看成本預覽。
- run 完成後：立即處理抽查樣本與 low / illegible 個案。
- 發布前：選定最終成績來源，檢查 Totals 與分數分布。

9 助教操作清單

階段	檢查事項
開始前	roster 匯入 (<code>student_id,name,email</code>)；三個辨識欄位區域已畫定 (務必上傳前畫好——之後修改不會重跑已辨識的頁面，finalize 後舊遮罩框也會殘留)；Providers / Methods / 每題 rubric 與參考解答就緒。

階段	檢查事項
上傳與識別	整疊上傳；在人工識別佇列逐頁確認（鍵盤 j / k / Enter，只能從名冊搜尋選人、不能自由輸入）；檢查「學生 × 題目」矩陣的缺格；finalize 可增量執行，缺格需明確確認。
校準批	檢查轉錄保真度、評語密度、扣分標準、複查標記。必要時請教師調整 rubric（產生新版本後重跑校準批）。
正式批改	一次 run 全班；核對成本預覽與上限；run 進度在 Runs 頁追蹤，失敗單元可重試。
run 完成後	完成強制抽查樣本；複查 low / illegible 與旗標個案；必要處填入人工後援分數。
發布前	在 Publish 選定最終成績來源；檢查 Totals 與分數分布；發布對話框會顯示寄件地址，確認無誤後送出。每位學生只會收到自己的批改結果——這在 v2 是系統結構性保證（逐生快照信件），不再靠人工核對附件。
發布後	學生直接回覆結果信、以 <code><p1>...</p1></code> 標籤指明題號申請 regrade；助教在 Regrade inbox 逐題裁決（可用 AI 複改輔助，僅供助教參考）；期限與輪次在 Regrade rounds 分頁控管；格式完全錯誤的回信不會消耗學生的申覆次數。

10 檔案結構：系統儲存與助教留存

v1 的 `course_grading_Q5/` 目錄樹（18 個 batch 資料夾、逐批 zip 與成績表）不再需要維護：原始頁、遮罩影像、轉錄、給分、評語與發布快照全部由系統儲存並納入每晚備份。助教本機只需保留：

```

course_grading/
├── scans/           原始掃描檔（上傳後留作備援）
│   └── final_exam_pile.pdf
└── roster/
    └── roster.csv   名冊（student_id,name,email）

```

需要交付或存檔時，由系統匯出：每位學生的結果 PDF（發布信附件，選項三種：不附檔、壓縮或原始品質；另可勾選改寄逐題 JPEG 的 zip，作為信箱附件大小限制的後備）、全班成績匯出（含退選標記）、以及單一學生的補寄（individual resend）。

11 建議時程

時間	工作
第 0 天	掃描全班考卷；匯入 roster；畫定三個辨識欄位區域。
第 1 天	上傳整疊、清人工識別佇列、finalize、遮罩審核；跑 5–10 份校準批；教師檢查並修正 rubric。
第 2 天	正式 run 全班；完成強制抽查樣本與 Review 複核、補人工後援分數。
第 3 天	選定最終成績來源；檢查 Totals 與分數分布；發布並寄送結果 PDF。
發布後	依 Regrade rounds 設定受理學生回信申覆；到期後由各題負責助教收尾。

較 v1 的 5 天時程縮短，主因是「分批上傳、逐批下載 zip、合併 18 份成績表」的人工步驟全部消失；多出來的時間應花在抽查與邊界個案上。

12 資料來源

本文件依 AdaGrade 專案文件與系統內建說明整理（部分沿用舊名 ADA-Marker）：

1. 系統內建使用指南（登入後左側 Guide 頁）——各分頁與控制項的完整說明；
2. `docs/OPERATIONS.md`——備份、還原與維運程序；
3. `docs/TA_DEPLOYMENT.md`——免 root 權限的工作站部署 (Docker Postgres + Cloudflare Tunnel)；
4. `docs/DECISIONS.md`——系統設計決策 (D1-D68)，含遮罩不變式、發布快照、regrade 規則等本文引用的機制。

v1 引用的 OpenAI Help Center 連結（上傳限制、Library 與檔案保留政策）已不再適用，僅存於 v1 文件供歷史參考。

附錄：v1 → v2 變更總覽

v2.1 (2026-07-20)：系統更名 AdaGrade (原 ADA-Marker)；v1 文件移至 docs/ta_batch_grading_guide_v1.pdf；修正三處描述——結果 PDF 附件選項、跨頁答案的處理 (conflict 而非 duplicate)、「修改辨識欄位區域的影響」。紅字仍表示相對 v1.0 的變更。

面向	v1 (ChatGPT 網頁)	v2 (AdaGrade)
批改引擎	ChatGPT 網頁對話，逐批上傳	自架系統直連批改 API，資料不進第三方介面
匿名化	人工裁切 + 匿名編號對照表	系統遮罩 + 身分/內容分離，遮罩審核閘門強制
分批	每批約 10 份、共 18 批	全班一次 run；由四道閘門與成本煞車控管
提示詞	每批貼範本、人工維護	內建 transcribe-then-grade 模板，隨方法版本化
輸出	.tex / .pdf / xlsx / csv / zip 手動合併	系統儲存全部紀錄；發布信附結果 PDF、成績可匯出
抽查	自律建議：每批 2-3 份	強制閘門：min(max(5, 5%), 20) 跨題分層樣本
複查標記	needs_human_review 欄位	confidence 自動標記 + 旗標 + 人工後援分數
發布	人工逐一寄送、自行核對	快照發布、逐生信件結構性隔離、可個別補寄
申覆	(未涵蓋)	學生回信 <p1> 標籤申覆，輪次與期限內建